Projekt 9: Bezpieczna Detekcja Spamu na Danych Zaszyfrowanych Szyfrem Homomorficznym Pailliera

Nazwa angielska: Privacy-Preserving Spam Detection Using the Paillier Cryptosystem

Słownik skrótów: PHE (Partially Homomorphic Encryption), TF-IDF (Term Frequency–Inverse Document Frequency), NB (Naive Bayes), SMS (Short Message Service).

1. Opis i cel projektu

Celem projektu jest implementacja demonstracyjnego systemu klasyfikacji wiadomości SMS jako spam lub ham (wiadomość prawidłowa), wykorzystującego algorytm Multinomial Naive Bayes oraz szyfrowanie homomorficzne Pailliera.

System powinien umożliwiać klasyfikację wiadomości bez konieczności ujawniania serwerowi ich treści ani niezaszyfrowanych wartości cech.

Głównym celem jest przedstawienie możliwości wykonywania obliczeń na danych zaszyfrowanych i ocena wpływu szyfrowania na czas działania klasyfikatora.

2. Kontekst praktyczny i znaczenie problemu (Use Case)

W tradycyjnych rozwiązaniach antyspamowych treść wiadomości może być analizowana przez zewnętrzny serwer, co stwarza ryzyko naruszenia prywatności użytkowników i ujawnienia poufnych informacji. Zastosowanie szyfrowania homomorficznego pozwala ograniczyć to ryzyko poprzez wykonywanie obliczeń bez odszyfrowywania danych przez usługodawcę. Rozwiązanie mogłoby znaleźć zastosowanie w chmurowych usługach filtrowania wiadomości, w których dostawca usługi nie powinien mieć dostępu do treści korespondencji klientów.

3. Problem badawczy i hipoteza

Pytanie badawcze:

Czy zastosowanie szyfrowania homomorficznego Pailliera umożliwia klasyfikację wiadomości SMS algorytmem Naive Bayes bez ujawniania serwerowi jawnych wartości cech, przy zachowaniu wyników porównywalnych z klasyfikacją na danych niezaszyfrowanych?

Hipoteza badawcza:

Zastosowanie szyfrowania Pailliera pozwala uzyskać co najmniej 95% zgodności decyzji klasyfikacyjnych z modelem działającym na danych jawnych, przy jednoczesnym zwiększeniu czasu przetwarzania wiadomości. Hipoteza zostanie zweryfikowana poprzez porównanie wyników klasyfikacji i czasów wykonania obu wariantów na tych samych wiadomościach testowych.

4. Scenariusz i model zagrożeń (Threat Model)

Zakładamy model Honest-but-Curious Cloud Server. Serwer poprawnie wykonuje obliczenia, jednak może próbować poznać dane przetwarzane przez klientów.

System składa się z dwóch logicznych komponentów:

- **Klient:** przetwarza wiadomość SMS do postaci wektora TF-IDF, szyfruje cechy kluczem publicznym, przesyła dane do serwera i odszyfrowuje otrzymany wynik.
- **Serwer:** posiada wcześniej wytrenowany model klasyfikacyjny i wykonuje obliczenia na zaszyfrowanych cechach, wykorzystując własności homomorficzne Pailliera.

Klucz prywatny pozostaje wyłącznie po stronie klienta. Trenowanie modelu odbywa się na jawnych danych ze zbioru publicznego.

5. Baza danych i charakterystyka danych

Zbiór: SMS Spam Collection Dataset - UCI Machine Learning Repository

https://archive.ics.uci.edu/dataset/228/sms+spam+collection

Zbiór zawiera 5574 wiadomości SMS podzielone na dwie klasy: spam oraz ham. Dane udostępniane są w postaci tekstowej (wiadomość i etykieta oddzielone tabulatorem), z możliwością konwersji do formatu CSV.

Wiadomości zostaną przekształcone na numeryczne wektory cech metodą TF-IDF. Można ograniczyć słownik, np. do 500 cech, w celu zmniejszenia kosztu obliczeń homomorficznych.

Proponowany podział danych: 80% zbiór treningowy, 20% zbiór testowy, z zachowaniem proporcji klas.

6. Zakres prac i etapy realizacji

Etap I - Przygotowanie danych i modelu

- Wczytanie zbioru SMS Spam Collection.
- Podział danych na zbiór treningowy i testowy.
- Wektoryzacja tekstu metodą TF-IDF.
- Wytrenowanie klasyfikatora Multinomial Naive Bayes.
- Ocena skuteczności klasyfikacji na danych jawnych.

Etap II - Implementacja szyfrowania

- Wykorzystanie biblioteki phe (Python Paillier).
- Generowanie pary kluczy.
- Szyfrowanie wartości wektorów cech przygotowanych przez klienta.
- Obsługa wartości zmiennoprzecinkowych.

Etap III - Klasyfikacja na danych zaszyfrowanych

- Implementacja obliczania wyników klasyfikatora przy wykorzystaniu operacji homomorficznych.
- Przesyłanie zaszyfrowanego wyniku do klienta.
- Odszyfrowanie wyniku i przypisanie wiadomości do klasy spam lub ham.

Etap IV - Testy i porównanie

- Porównanie wyników klasyfikatora działającego na danych jawnych i zaszyfrowanych.
- Pomiar czasu szyfrowania, klasyfikacji i odszyfrowania.

- Przedstawienie podstawowych ograniczeń zastosowanego rozwiązania.
- Weryfikacja hipotezy badawczej.

7. Kryteria realizacji i oceny

1. Poprawne działanie klasyfikatora Naive Bayes na publicznym zbiorze wiadomości.
2. Docelowy Recall dla klasy spam ≥ 90%, przy raportowaniu również Precision, Accuracy, F1-score i macierzy pomyłek.
3. Uzyskanie co najmniej 95% zgodności decyzji klasyfikacyjnych dla danych jawnych i zaszyfrowanych na wybranej próbce testowej.
4. Wykazanie, że serwer może obliczyć wynik bez posiadania klucza prywatnego i dostępu do jawnego wektora cech.
5. Przedstawienie porównania kosztu czasowego obu wariantów.

8. Ograniczenia i wymagania implementacyjne

Projekt ma charakter demonstracyjny. Dopuszczalne jest ograniczenie liczby cech i wiadomości wykorzystywanych w eksperymentach homomorficznych w celu skrócenia czasu obliczeń.

Nie jest wymagane przygotowanie interfejsu graficznego, wdrożenie chmurowe, samodzielna implementacja szyfru Pailliera ani trenowanie modelu na zaszyfrowanych danych. Wystarczająca jest aplikacja konsolowa w języku Python, prezentująca działanie klienta i serwera oraz podstawowe wyniki eksperymentów.

9. Literatura i narzędzia

1. Paillier, P. (1999). *Public-Key Cryptosystems Based on Composite Degree Residuosity Classes*. EUROCRYPT '99.
2. Python Paillier Library (phe) - https://github.com/data61/python-paillier
3. Scikit-learn - dokumentacja MultinomialNB i TfidfVectorizer.
4. UCI Machine Learning Repository - SMS Spam Collection Dataset.